AI4HEALTH. CRO

Natjecateljski izazov 2026. u partnerstvu s AstraZeneca i Novo Nordisk Hrvatska

TEST.

LEARN.

COLLABORATE.

FUND.

PREMIUM PARTNER

AstraZeneca

CHDC

STANDARD PARTNER

novo nordisk

Co-funded by the European Union

EDIH

ai4health

OŽUJAK, 2026

www.ai4healthcro.eu / edih@irb.hr

IZAZOV ZA 2026.

AI U SLUŽBI DIJABETESA

ZAŠTO?

- Dijabetes tipa 2 je u porastu (1 od 3 osobe nediagnosticirani)
- Svaka deseta odrasla osoba ima dijabetes (66 milijuna ljudi u EU)
- Približno 44 % osoba s dijabetesom tipa 2 (T2D) ne pridržava se terapije
- Hrvatska: U populaciji 409.000 osoba boluje od dijabetesa
- Prevalencija dijabetesa 2024. je 10,5

To dovodi do:

- lošijih ishoda, komplikacija i češćih hospitalizacija (35 % veći rizik hospitalizacija i posjeta hitnoj službi)
- većih troškova za zdravstveni sustav (193 milijarde USD u EU)
- nepridržavanje kardiovaskularnih i metaboličkih smjernicapovećava rizik od 3P-MACE događaja za 49%

OD INOVACIJE DO IMPLEMENTACIJE

OPIS PROBLEMA

Polazni problem je da značajan dio pacijenata s dijabetesom tipa 2 pada **ispod definirane razine adherencije**, odnosno ne uzima redovito propisanu terapiju.

Takvo odustajanje od liječenja izravno dovodi do lošijih zdravstvenih ishoda, ozbiljnih komplikacija, češćih hospitalizacija i velikog financijskog opterećenja za cijeli zdravstveni sustav.

RJEŠENJE

Rano prepoznavanje takvih pacijenta.
Intervencija za poboljšanje adherencije.
Mjerenje ishoda intervencije.

PREDIKCIJA.

OBJAŠNJENJE.

INTERVENCIJA.

POSLOVNI MODEL.

Metode mjerenja adherencije

DIREKTNE METODE

Biokemijska analiza krvi ili urina, ingestibilni senzori (pametne tablete).

SUBJEKTIVNE METODE

Strukturirani upitnici za pacijente, intervjui, samo-izvještavanje.

RWD / PODACI IZ STVARNOG SVIJETA

Analiza digitalnih baza podataka o propisanim i izdanim receptima (PDC metrika).

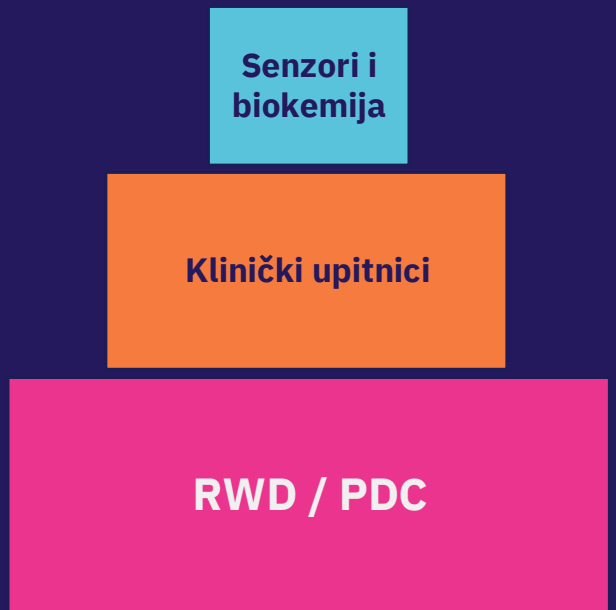

Proportion of days covered (PDC)

OPIS

Mjeri udio dana u određenom razdoblju kada pacijent ima dostupnu propisanu terapiju

Kako se interpretira?
PDC ≥ 80% → dobra adherencija
PDC < 80% → suboptimalna adherencija

ZADATAK

Predvidjeti adherenciju za osobe s T2DM u zadanom momentu

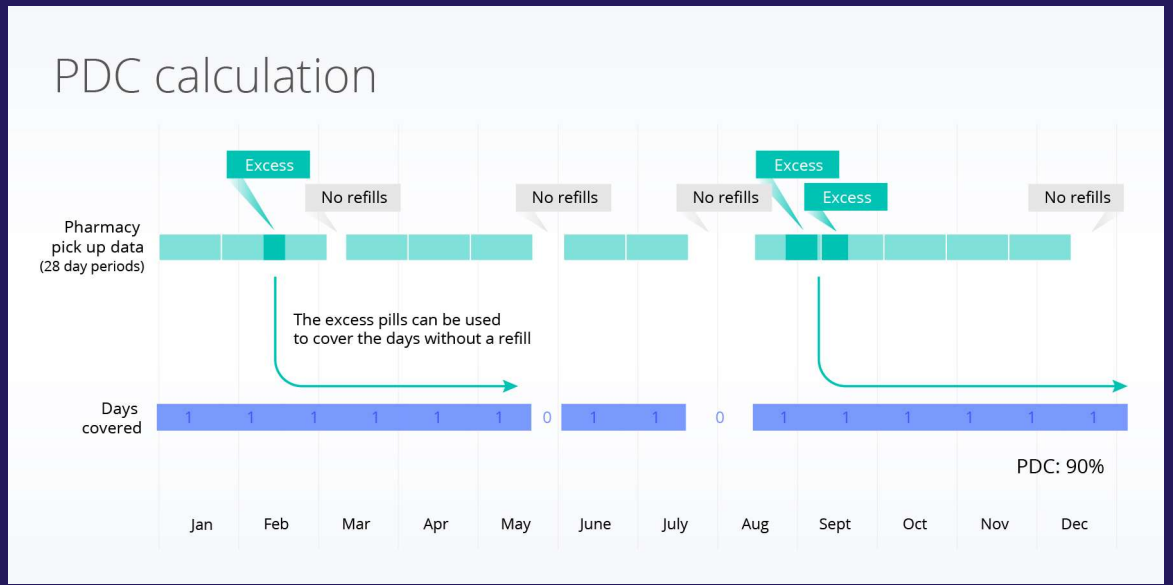

Izvor: https://www.truveta.com/blog/research/variation-in-medication-adherence-for-type-2-diabetes-patients/

Podaci na kojima radite

- **Stvarni, anonimizirani podaci iz primarne zdravstvene zaštite**
  - Ekstrakcija iz baze prema kriterijima: kohorta osoba s mogućim T2DM
- **Primjena fenotipizacijskih algoritama**
  - ↑PPV za T2DM, selekcija osoba za izračun PDC mjere
- **Transformacija u podatkovni standard**
  - Harmonizacija na OMOP CDM za sekundarnu uporabu med. podataka
- **Izračun PDC mjere**
  - U trenutku započinjanja nove terapije s neinzulinskim antidijabeticima

OHDSI
Observational Health Data Sciences and Informatics

IZAZOV ZA 2026.

SPE– Secure Processing Environment

RAČUNALNO OKRUŽENJE SPE

→8 vCPUs
→16 GB RAM
→400 GB disk space

Spajanje

→https://chdc.hzjz.hr/
→Username i password koje će voditelj tima dobiti

TU SMO!

Objava poziva	Zatvaranje poziva	Obavijest sudionicima	Kick off (ZICER/Online)	Meetup (ZICER /Online)	Kraj natjecanja	Evaluacija i obavijest sudionika
16. 2.2026.	9.3.2026. 12:00	17.3.2026.	24.3.2026 9:45	23.4.2026. Vrijeme održavanja bit će objavljeno putem emaila i na forumu	Predaja Finalnih rješenja 7.5.2026. 23:59	Objavit će se putem emaila i foruma Demo day (godišnja konferencija) 19.5.2026. Vrijeme održavanja bit će objavljeno putem emaila i na forumu

IZAZOV ZA 2026.

ZADAĆI I BODOVANJE

Zadatak 1. Predikcija adherencije i medicinska interpretacija modela

a) Prediktivni model za PDC – 20 bodova – do 10 za validaciju + 1 finalna predaja rješenja za prediktivni dio u CSV formatu!

- Natjecatelji trebaju razviti prediktivni model adherencije temeljen na:
- PDC (Proportion of Days Covered) mjeri, za terapiju **neinzulinskim antidijabeticima**, vremenski okvir godina dana.
- Binarni klasifikacijski problem PDC>=0.8 - **ADHERENTAN**, PDC<0.8 **NEADHERENTAN**
- Metrika za evaluaciju je **MCC**.

b) Medicinska interpretacija modela – 20 bodova

- Relevantnost najvažnijih prediktora ili prediktorskih obrazaca koje je model identificirao,
- Ulogu značajki u oblikovanju adherencije na terapiju, pri čemu navedena relevantnost treba biti potkrijepljena analizom podataka dostupnih u okviru ovog natjecanja i relevantnom literaturom gdje je dostupna.

UPUTA ZA ZADATAK 1.a
IZVJEŠTAJ TREBA BITI USKLAĐEN SA STANDARDIMA ZA TRUSTWORTHY AI TE MORA UKLJUČIVATI:

→ **Reproducibilan kod (.py, .r, .sql, ...)**
→ **Tehničku dokumentaciju**
- opis razvoja modela
- opis korištenih podataka i metoda pripreme
- opis programskog rješenja
- opis metodologije evaluacije i selekcije modela
- karakteristike prediktivnog modela
- *maksimalno **2 stranice** teksta uključujući slike. Format dokumenta je pdf. Predaja se vrši iz SPEa u submission folder.*

CHALLENGE JOURNEY

Rezultati zadatka 1.a prate se na leaderboardu:
https://ai4healthcro.eu/?ht_kb=ljestvica-rezultata-ai4health-cro-inovacijskog-natjecanja-2026

AstraZeneca
CHDC
novo nordisk
Co-funded by the European Union
EDIH European Digital Innovation Hubs Network
ai4health
REPUBLIC of CROATIA Ministry of Economy

UPUTA ZA ZADATAK 1.b Medicinska interpretacija modela

→ **Kod koji generira rezultate za klinički primjenjive intervencije za poboljšanje adherencije (.sql i .ipynb, .rmd -> html, ...)**
- Napomena: slike u bilježnici moraju odgovarati slikama u .pdf opisu.

→ **Dokument pdf je usklađen s kriterijima za ocjenu rješenja i evaluacijskim kriterijima zadatka 1.b.**
- Napomena: medicinska interpretacija modela sadrži maksimalno **3 stranice**, minimalna veličina fonta teksta je 11. pdf dokument i skripte se izrađuju u SPE.

KRITERIJI ZA OCJENJIVANJE:

→ Identifikacija ključnih prediktora/prediktorskih obrazaca
→ Njihova povezanost s adherencijom i objašnjenje mehanizama
→ Potkrepljenost podacima i literaturom

ŠTO EVALUIRAMO

→ Cilj nije samo predikcija, već **klinički korisna interpretacija**, **pravovremena intervencija za poboljšanje adherencije** u **primarnoj zdravstvenoj skrbi** i **poslovna evaluacija**.

→ Finalna predaja rješenja uključuje **dokumente pdf** i **skripte** i **kodove**

- Kod mora biti čitljiv, reproducibilan i jasno dokumentiran.
- Svi rezultati trebaju biti imati odgovarajući kod koji ih producira u notebooku ili markdownu.

→ Sami odabirete koje predikcije predajete kao **finalno rješenje** za Zadatak 1.a, vaša **zadnja predaja je finalna – nju se evaluira na čitavom holdout (evaluacijskom) skupu podataka**.

IZAZOV ZA 2026.

ZADACI I BODOVANJE

Zadatak 2: Prijedlog klinički primjenjive intervencije za poboljšanje adherencije i prototip aplikacije

a) (40 bodova) Intervencija za poboljšanje adherencije.

→ temeljem saznanja iz dobivenih podataka o pacijentima trebaju predložiti jedno rješenje problema neadherencije na terapiju, a koje će se koristiti na primarnom nivou zdravstvene skrbi (liječnici obiteljske medicine).

→ Rješenje treba biti utemeljeno na analizi podataka iz ovog natjecanja, klinički i procesno smisleno te jasno obrazloženo, uz objašnjenje na koji način se može primijeniti na poboljšanje adherencije u ciljanoj populaciji.

b) (20 bodova) Poslovna evaluacija aplikacije za liječnike obiteljske medicine

→ Prototip aplikacije za liječnike obiteljske medicine.

→ Odgovoriti na pitanje “Da li je rješenje za definirani problem tržišno skalabilno?”.

→ Objasniti, što konciznije i utemeljenije, kakav učinak predviđaju na populacijskoj razini te kakve su koristi implementacije rješenja za pacijente, liječnike i za zdravstveni sustav u cjelini.

→ Video pitch u trajanju do 5 minuta.

UPUTA ZA ZADATAK 2.a Intervencija za poboljšanje adherencije

→ Kod koji generira rezultate za klinički primjenjive intervencije za poboljšanje adherencije (.sql i .ipynb, .rmd -> html, ...)
!Napomena: slike u bilježnici moraju odgovarati slikama u .pdf opisu.

→ **Dokument pdf je usklađen s kriterijima za ocjenu rješenja i evaluacijskim kriterijima zadatka 2.a.**

!Napomena: rješenje zadatka sadrži **maksimalno 6 stranica**, minimalna veličina fonta teksta je 11. pdf dokument i skripte se izrađuju u SPE.

KRITERIJI ZA OCJENJIVANJE:

→ Inovativnost rješenja
→ Klinička relevantnost odabranog problema i procesna izvedivost rješenja
→ Jasnoća i razrađenost obrazloženja načina na koji se rješenje može primijeniti za poboljšanje adherencije u ciljanoj populaciji
→ Utemeljenost prijedloga na analizi podataka iz ovog natjecanja

UPUTA ZA ZADATAK 2.B POSLOVNA EVALUACIJA APLIKACIJE ZA LIJEČNIKE OBITELJSKE MEDICINE

OCIJENJUJE SE

- → Video pitch u trajanju do 5 minuta usklađen s uputom, kriterijima za ocjenu rješenja i evaluacijskim kriterijima zadatka 2.b.
- → Prototip aplikacije.

EVALUACIJSKI KRITERIJI - POSLOVNI:

- → Objašnjenju učinka rješenja na populacijskoj razini
- → Objašnjenju vrijednosti koje rješenje donosi za liječnike i pacijente
- → Objašnjenju dugoročnih koristi za zdravstveni sustav nakon uvođenja rješenja

IZAZOV ZA 2026.

Bodovanje 1. zadatka

- Za svako finalno rješenje, odrede se predikcije prema združenom **evaluacijskom skupu (validacijski + testni skup)** za model koji predviđa vrijednos PDC.
- Formira se poredak na temelju evaluacijske mjere: **Mjera -> MCC**.
- Bootstrap uzorkovanje na evaluacijskom skupu: Odredi se slučajnim uzorkovanjem **n** stratificiranih skupova (***bootstrap* uzoraka - bi**) na evaluacijskom skupu kojima se pridruže odgovarajući skupovi **predikcija natjecatelja - pi**. Skup rješenja A na bootstrap uzorcima je:

$$A = \{A_i = Mjera(b_i, p_i) : i \in \{1, \ldots, 500+\}\}$$

1. **2r** je ukupna duljina **intervala pouzdanosti (CI)** od svih rješenja tima A (A_i)
2. s - standardna devijacija
3. z je kritična vrijednost razdiobe od 2.5%

$$\Longrightarrow \boxed{2r} = mean(A) \pm z\frac{s}{\sqrt{n}}$$

IZAZOV ZA 2026.

Bodovanje 1. zadatka

Poredak se formira na temelju:

- **finalnog rješenja**, apliciranog na
- združeni **evaluacijski skup (validacijski + testni skup).**

Bodovanje:

- rješenje najboljeg tima dobija maksimalnih 20 bodova
- ostalim rješenjima se bodovi određuju na temelju razlike u odnosu na najbolje ocjenjeni (na svakoj iteraciji i)

„Meetup” događanje -> finalna definicija bodovanja 1. zadatka

IZAZOV ZA 2026.

KOMUNIKACIJA SA NATJECATELJIMA

WEB stranica (https://ai4healthcro.eu)

Tehničke upute: Opis zadatka, podataka i postupak evaluacije rješenja

→ **Forum** je medij za pitanja vezana uz izazov (Pitanja & Odgovori)

→ Autentikacija timova za pristup Forumu!

→ Ljestvica rezultata

U izuzetnim slučajevima Timovi komuniciraju s organizatorom (ZICER) preko jedne e-mail adrese (voditelj tima)

FORUM

→ Trebali ste dobiti email od:
wordpress@ai4healthcro.eu

→ Molimo provjerite!

→ Pitanja i odgovori

AstraZeneca CHDC novo nordisk Co-funded by the European Union EDIH European Digital Innovation Hubs Network ai4health REPUBLIC of CROATIA Ministry of Economy

IZAZOVE RJEŠAVAJU ONI KOJI IH VODE.

Zajedno s partnerima i timovima definiramo što znači odgovorna inovacija u terapiji dijabetesa.
Hvala partnerima što prepoznajete priliku i potencijal!

PREMIUM PARTNER

AstraZeneca

U SURADNJI S

CHDC

STANDARD PARTNER

novo nordisk®

Sufinancira Europska unija

EDIH European Digital Innovation Hubs Network

ai4health CRO

REPUBLIKA HRVATSKA Ministarstvo gospodarstva

Projekt sufinancira Europska unija iz programa Digitalna Europa (DIGITAL).

ACADEMIC COMMUNITY

HEALTH ORGANISATIONS

ASSOCIATIONS

RB

Magdalena

CroAi

University of Rijeka Society of Engineering

Dom zdravlja Zagreb - Centar

Udruga poslodavaca u zdravstvu Hrvatske

Sveučilište u Splitu Medicinski fakultet University of Split School of Medicine

HZJZ

PUBLIC SECTOR

Ministry of Health

Croatian Health Insurance Fund

TECHNOLOGICAL COMPANIES

in2 GROUP

Ericsson Nikola Tesla

newton TECHNOLOGIES ADRIA

DEVELOPMENT AND FUNDING

ZICER Zagrebački inovacijski centar

Feelsgood CAPITAL PARTNERS

mrežaznanja

SUPPORTED BY

eit Health

ECHAlliance