Upute za korisnike

Materijali na SPE mašini

1. Tehnička dokumantacija
2. Baza podataka pacijenata u Observational Medical Outcomes Partnership (OMOP) common data model-u (CDM).
3. Okruženja python u d:\environment\. Instalirani paketi se nalaze u test_imports_*.py
4. R okruženje instalirane biblioteteke: d:\environment\env.R
5. sql skripta za računanje PDC-a u trening skupu podataka, značajke birate i generirate sami iz db OMOP.
6. instalirani su R studio i VS code.
7. Lista svih instaliranih softvera nalazi se u d:\environment\Preinstalls.txt

SPE

Na Secure processing environmentu postoje 3 python environmenta za razvoj challenge_env, challenge_torch i challenge_tensorflow, te R env.

Python okruženja se mogu pokrenuti iz powershella, te iz terminala u vs Code:

Aktivacija okruženja u powershellu:

1. „some_path“>& d:\environment\challenge_torch\Scripts\Activate.ps1
   (challenge_torch) PS D:\>
2. PS D:\> & d:\environment\challenge_tensorflow\Scripts\Activate.ps1
   (challenge_tensorflow) PS D:\>
3. PS D:\> & d:\environment\challenge_env\Scripts\Activate.ps1
   (challenge_tensorflow) PS D:\>

Datoteka test.pdf generirana je iz test.ipynb koristeći naredbu: **jupyter nbconvert --to pdf test.ipynb**

Duck DB i OMOP

Da biste pristupili OMOP bazi prvo preuzmite bazu sa shared diska.

Napravite više kopija baze kako bi više korisnika istovremeno moglo čitati i pisati podatke u duckdb ili izvadite podatke u neki drugi oblik (npr. csv, parquet)

GUI za rad s bazom može se pokrenuti pomoću naredbe, **duckdb.exe** nije dodan u path od windows environmenta ili se nalazite u direktoriju s **./duckdb.exe** ili dati punu putanju „d:/environment/duckdb.exe“:

```./duckdb.exe "D:\omop.duckdb" -ui```, ili

```d:/environment/duckdb.exe "D:\omop.duckdb" -ui```.

Naredba pokreće GUI za SQL upite na OMOP bazu. GUI duckdb se nalazi u browseru na adresi: **http://localhost:4213/**

OMOP CDM

Za generiranje značajki za vaš problem možete koristiti sve tablice koje se nalaze u bazi u shemi *cdm_omop*. Neke od tablica gdje se nalaze potencijalno relevantne kliničke značajke su:

- condition_occurrence
- observation
- device_exposure
- drug_exposure
- measurement
- procedure_occurance

PDC i train-test split

U shemi *cdm_omop_results* nalazi se se kohorta pacijenata s T2DM koja je zadovoljila kriterije za izračun PDC-a.

Tablica *train_test_cohort* sadrži train-test split navedene kohorte s izračunatim PDC-om u razdoblju između *cohort_start_date* i *cohort_end_date*. Varijabla *drug_class* označava klasu antidijabetika koju je pacijent prvi put počeo uzimati na datum *cohort_start_date* te je pokretač izračuna adherencije u sljedećem razdoblju od godinu dana. Varijabla *adherent* označava pacijente čiji je izračunati PDC >= 0.8. Varijabla *subject_id* odnosi se na pacijente iz OMOP CDM baze (*person_id).*

Predaja rezultata predikcije

Predikciju za test set predajete u CSV datoteci (zarez kao delimiter) s kolumnama *row_id, label, score.*

- *row_id* – vrijednost istoimenog identifikatora iz *train_test_cohort* tablice
- *label* – označava da je pacijent neadherentan (1) ili adherentan (0)
  !Pripazite na oznaku jer u tablici *train_test_cohort* imate vrijednost 1 za adherenciju u varijabli *adherent*
- *score* – kontinuirani numerički output vašeg modela (npr. vjerojatnost, PDC)

Tijekom natjecanja možete 10 puta predati rješenje na validaciju. **Vaše zadnje rješenje je finalno rješenje, tehnička podrška ne bira koje je najbolje već zadnje rješenje šalje na bodovanje.** *Napomena:* Prije same predaje možete provjeriti broj redaka vašeg outputa i da li su svi row_id koji odgovaraju testnim primjerima zastupljeni u generiranoj csv datoteci.

Sretno na natjecanju,

tehnička podrška